Projeto Integrador — Abandono Escolar em Cubatão-SP

Relatório de metodologia e resultados, para apresentação e aprovação do grupo

1. Introdução e objetivo

Este relatório documenta, passo a passo, o desenvolvimento do Projeto Integrador sobre abandono escolar na rede municipal de Cubatão-SP. O objetivo central é construir uma análise de dados educacionais que combine o contexto oficial da rede municipal (Censo Escolar e Taxas de Rendimento do INEP) com um estudo de caso detalhado de frequência escolar, culminando em um índice de risco de evasão e uma prova de conceito de Machine Learning.

O recorte do estudo é o Ensino Fundamental — Anos Finais (6º ao 9º ano) da rede municipal, com o 7º ano isolado tratado como o foco mais detalhado desde o início do projeto.

2. Transparência dos dados — o que é real e o que é fictício

Este é o ponto mais importante para a aprovação do grupo: o projeto combina dados reais e dados fictícios/simulados, e cada peça está claramente identificada. A tabela abaixo resume a origem de cada fonte usada.

Fonte de dados	Origem	Cobertura
Censo Escolar do INEP (2024 e 2025)	REAL	Todas as escolas municipais de Cubatão, oficial
Taxas de Rendimento Escolar do INEP (2024 e 2025)	REAL	Aprovação/reprovação/abandono, rede municipal, oficial
Fluxo Escolar SEDUC-SP (2011–2024)	REAL (mas descartado)	Rede estadual — não corresponde à rede municipal, por isso não foi usado na análise principal
Chamada diária — turmas de 7º, 8º e 9º ano (2026)	REAL	Digitalizada a partir da planilha de chamada de uma escola, turno da manhã (12 turmas, 321 alunos)
Chamada diária — turmas de 6º ano (2026)	FICTÍCIO	Simulado estatisticamente (mesmo método usado para o turno da tarde), pois o arquivo original não continha 6º ano
Chamada diária — turno da tarde (todas as séries)	FICTÍCIO	Simulado estatisticamente; nenhum turno da tarde foi digitalizado
Base "Predict Students' Dropout" (UCI, Realinho et al. 2021)	REAL	4.424 alunos reais de instituição de ensino superior portuguesa — usada como prova de conceito de Machine Learning, não é dado de Cubatão
Tabela com rótulo de resultado sintético (extensão de ML)	FICTÍCIO (rótulo)	Frequência real (manhã, 7º-9º) + fictícia (tarde) — mas o resultado final (Evasão/Matriculado/Diplomado) é sorteado, não observado

Nome fictício da escola: para preservar a identidade da unidade escolar real que forneceu a chamada, o projeto usa o nome fictício "Escola Municipal de Cubatão" em todo o estudo de caso.

3. Etapas do projeto, passo a passo

Etapa 1 — Censo Escolar do INEP (2024 x 2025)

Filtramos as tabelas do Censo Escolar (Escola, Matrícula, Turma, Docente, Gestor) para o município de Cubatão-SP e isolamos a rede municipal (TP_DEPENDENCIA = 3), comparando 2024 com 2025.

- Escolas municipais: 57 em 2024 → 54 em 2025
- Matrículas de 7º ano: 915 (2024) → 919 (2025)
- Matrículas de Anos Finais (6º-9º): 3.416 (2024) → 3.488 (2025)

Etapa 2 — Taxas de Rendimento Escolar do INEP (2024 x 2025)

Diferente do Fluxo Escolar do SEDUC-SP (que cobre a rede estadual), as Taxas de Rendimento do INEP cobrem a rede municipal diretamente, por escola (mesmo código CO_ENTIDADE do Censo) e por município.

- 7º ano — Aprovação: 91,7% (2024) → 93,1% (2025) · Reprovação: 7,3% → 5,4% · Abandono: 1,0% → 1,5%
- Anos Finais (6º-9º) — Aprovação: 92,8% (2024) → 94,4% (2025) · Reprovação: 6,4% → 4,6% · Abandono: 0,8% → 1,0%

Etapa 3 — Estudo de caso: "Escola Municipal de Cubatão" (2026)

Reunimos a chamada diária de 16 turmas (6º ao 9º ano, turno da manhã) do 2º trimestre de 2026, cobrindo 425 combinações aluno-turma.

- 6º ano: 4 turmas, 104 alunos — FICTÍCIO
- 7º ano: 4 turmas, 94 alunos — REAL
- 8º ano: 5 turmas, 137 alunos — REAL
- 9º ano: 3 turmas, 90 alunos — REAL
- 55,1% dos 425 alunos tiveram frequência abaixo de 75% em pelo menos um mês do trimestre

Etapa 4 — Índice de risco combinado

Inspirado em três Projetos Integradores de referência da UNIVESP sobre controle de frequência, busca ativa escolar e monitoramento de risco acadêmico, construímos um índice somando pontos de três sinais: frequência média, tendência entre o primeiro e o último mês, e maior sequência de faltas consecutivas.

- Critério: frequência < 75% (+3) ou < 85% (+1) · queda ≥ 10 p.p. (+2) ou ≥ 5 p.p. (+1) · 3+ faltas seguidas (+2) ou 2 (+1)
- Classificação: score ≥ 5 = Alto risco · 2 a 4 = Médio · 0 ou 1 = Baixo
- Resultado: 32,7% Baixo · 35,5% Médio · 31,8% Alto risco, entre os 425 alunos

Etapa 5 — Protótipo de ferramenta: registro digital de frequência

Como extensão prática, construímos um protótipo web (HTML autocontido, sem necessidade de instalação) que demonstra um registro de chamada digital com alertas automáticos, usando o mesmo índice de risco da Etapa 4. O protótipo diferencia claramente escolas/anos com dado real (2026, Escola Municipal de Cubatão, turno da manhã) dos que mostram apenas contexto oficial (2024/2025, escolas reais da rede, sem chamada digitalizada).

Etapa 6 — Prova de conceito de Machine Learning

Como os dados de Cubatão não têm um rótulo de resultado real por aluno (não sabemos quem evadiu de fato), praticamos a técnica de Machine Learning supervisionado em duas etapas:

- Base pública real (UCI): 4.424 alunos, com rótulo real de Evasão/Matriculado/Diplomado. Random Forest atingiu 77% de acerto. As variáveis mais importantes foram as acadêmicas (unidades aprovadas, notas), não as socioeconômicas — validando a priorização de frequência/aprovação que o PI já adotava.
- Extensão na estrutura de Cubatão: uma tabela de 202 alunos (manhã real + tarde fictícia) com rótulo de resultado sintético (sorteado, correlacionado ao risco) foi usada para testar o mesmo pipeline nas colunas reais de Cubatão. Resultado: 51% de acerto — modesto, mas acima do acaso (33% para 3 classes),

demonstrando que o pipeline funciona, mas destacando que falta um rótulo real para virar um modelo válido de fato.

4. Limitações reconhecidas

- O estudo de caso de 2026 cobre uma única escola e apenas o turno da manhã — não representa a rede municipal inteira.
- O 6º ano e o turno da tarde são inteiramente fictícios/simulados, não observados na realidade.
- Não existe rótulo de resultado real (evasão/aprovação) por aluno em Cubatão — por isso a Etapa 6 usa uma base externa (UCI) e, na extensão, um rótulo sintético.
- O protótipo de registro de frequência não persiste dados entre sessões (é uma demonstração, não um sistema em produção).

5. Próximos passos — decisões para o grupo

- Aprovar (ou ajustar) o escopo atual antes da redação final do PI
- Decidir se o grupo quer buscar dados reais de 6º ano e do turno da tarde para substituir a simulação
- Decidir se o PI permanece como notebooks de análise ou evolui para uma ferramenta completa (registro de frequência + alertas automáticos + busca ativa), inspirada nos três TCCs de referência
- Se possível, buscar as Taxas de Rendimento de anos anteriores a 2024 para ampliar a série histórica municipal

6. Referências

INEP — Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira. Censo Escolar da Educação Básica e Taxas de Rendimento Escolar, 2024 e 2025. Disponível em: gov.br/inep.

Realinho, V., Vieira Martins, M., Machado, J., & Baptista, L. (2021). Predict Students' Dropout and Academic Success [Dataset]. UCI Machine Learning Repository. https://doi.org/10.24432/C5MC89

Três Projetos Integradores de referência da UNIVESP (2024/2026), sobre controle de frequência, busca ativa escolar e monitoramento pedagógico de risco acadêmico — citados nas Etapas 4 e 5.